Beschreibende Statistik

Lageparameter

Arithmetisches Mittel

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{1}{n}(x_1 + \dots + a_n)$$

Geometrisches Mittel

$$\bar{x}_{geom} = \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n}$$

Median

$$\tilde{x} = \begin{cases} x_{\frac{n+1}{2}}, ungerade \\ \frac{1}{2}(x_{\frac{n}{2}} + x_{\frac{n}{2}+1}), gerade \end{cases}$$

Der Median $\tilde{x}$ minimiert die Funktion $\sum_{i=1}^{n} |x_i - \bar{x}|$

Streungsmaße

(empirische) Varianz

$$var = \sigma^2 = s_n{}^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Standardabweichung

$$\sigma = s_n = \sqrt{\sigma^2}$$
$$\sigma = s_n = \sqrt{s_n{}^2}$$

mittlere absolute Abweichung

$$\frac{1}{n}\sum_{i=1}^{n}|x_i - \tilde{x}| \text{ für Median}$$
$$\frac{1}{n}\sum_{i=1}^{n}|x_i - \bar{x}| \text{ für arithmetisches Mittel}$$

Kovarianz und Korrelationskoeffizient

Kovarianz

$$cov(x,y) = S_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x}) \cdot (y_i - \bar{y})$$

Korrelationskoeffizent

$$r_{xy} = \frac{S_{xy}}{S_x \cdot S_y}$$

Der Korrelationskoeffizent liegt immer zwischen $-1 \leq r \leq +1$. Je näher r_{xy} bei -1 (negative Korellation/Steigung), oder $+1$ (positive Steigung/Korrelation) liegt, desto genauer schmiegen sich die Messwerte an eine Gerade an. Bei r_{xy} nahe 0 gibt es keinen *linearen* Zusammenhang zwischen den Merkmalen.

Regressionsrechnung

Regressionsgerade

Variante 1

$$y = \bar{y} + \frac{S_{xy}}{\sigma_x{}^2} \cdot (x - \bar{x})$$

Variante 2

$$y = b + a \cdot x$$
$$a = \frac{S_{xy}}{\sigma_x{}^2} \text{ und } b = \bar{y} - a \cdot \bar{x}$$

Kleinste quadratische Abweichung

Die Parameter $a, b, c, \ldots$ werden so gewählt, dass

$$Q(a,b,c,\ldots) = \sum_{i=1}^{n}(y_i - f_{a,b,c,\ldots}(x_i))^2$$

minimal ist

$f_{a,b,c\ldots}(x_i)$ ist die Funktion dessen Parameter gesucht werden

Nullsetzen der partiellen Ableitungen:

$$\frac{\delta}{\delta a}Q(a,b) = 0$$
$$\frac{\delta}{\delta b}Q(a,b) = 0$$

Über die Ableitungen lassen sich die Parameter finden welche die vorgegebene Funktion am besten annähern

Vergleich ermittelter Kurven

Um Kurven zu vergleichen, einfach die ermittelten Parameter in die $Q(a,b,c,\ldots)$ Funktion eingeben und Wert berechnen. Je kleiner der Wert desto besser passt die Kurve

Wahrscheinlichkeitstheorie

Wahrscheinlichkeitsräume

Der Wahrscheinlichkeitsbegriff

$$Ergebnismenge = \Omega$$

Beispiel Würfel $\Omega = \{1,2,3,4,5,6\}$

Ein Ereignis ist eine Teilmenge der Ergebnismenge

$\varnothing \subseteq \Omega \mathrel{\widehat{=}}$ unmögliches Ereignis

$\Omega \subseteq \Omega \mathrel{\widehat{=}}$ sicheres Ereignis

$A = \{1,2,3\}$ Ereignis

$\bar{A} = \{4,5,6\}$ Gegenereignis

Elementarereignis

einelementige Teilmenge von Ω

Ereignis, eine 3 werfen

$$B = \{3\}$$
$$P(\{3\}) = \frac{1}{6}$$

Laplace-Versuch

Jedes Elementarereignis ist gleich wahrscheinlich

$$P(\{\omega_i\}) = \frac{1}{|\Omega|}$$
$$P(A) = \frac{|A|}{|\Omega|} = \frac{3}{6} = \frac{1}{2}$$

Bedingte Wahrscheinlichkeit

Bedingte Wahrscheinlichkeit

Wahrscheinlichkeit für A unter der Bedingung B

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$
$$P(\bar{A}|B) = 1 - P(A|B)$$

Formel von Bayes

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Satz der totalen Wahrscheinlichkeit

$$P(A) = \sum_{i}^{n}(P(A|B_i) \cdot P(B_i)$$

Viel Felder Tafel

	A	$\bar{A}$	$\sum$
B	$P(A \cap B)$	$P(\bar{A} \cap B)$	$P(B)$
$\bar{B}$	$P(A \cap \bar{B})$	$P(\bar{A} \cap \bar{B})$	$P(\bar{B})$
$\sum$	$P(A)$	$P(\bar{A})$	1

Die Ränder sind immer die Summen der zugehörigen Zeilen oder Spalten

Allgemeine Regeln

$$P(A \cap B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$
$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$
$$P(\bar{A}) = 1 - P(A)$$
$$P(A \bar{\cup} B) = P(\bar{A} \cap \bar{B})$$
$$P(A \bar{\cap} B) = P(\bar{A} \cup \bar{B})$$

Wenn A und B unabhängig, dann gilt

$$P(A \cap B) = P(A) \cdot P(B)$$

Zufallsvariablen

Eine Zufallsvariable ist eine Zuordnungsvorschrift die jedem möglichen Ergebnis eines Zufallsexperiments eine Größe zuordnet

$$X = k \mathrel{\widehat{=}} \{\omega \in \Omega | X(\omega = k\}$$
$$X = 3 \mathrel{\widehat{=}} \{\omega \in \Omega | X(\omega = 3\}$$
$$X \leq k \mathrel{\widehat{=}} \{\omega \in \Omega | X(\omega \leq k\}$$

Diskrete Verteilungen

Binomialverteilung

Mit zurücklegen, Wahrscheinlichkeit für jedes Ereignis gleich

$$X \sim B(n,p)$$

$n =:$ Stichprobenumfang

$p =:$ Wahrscheinlichkeit

(p muss bei Binomialverteilung fest bleiben)

$$P(X = k) = \binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$$
$$P(X \leq k) = \sum_{i=0}^{k}\binom{n}{i} \cdot p^i \cdot (1-p)^{n-i}$$
$$P(X > k) = 1 - P(X \leq k)$$

Eingabe Taschenrechner

$$\binom{n}{k} \mathrel{\widehat{=}} n\,|nCr|\,k$$

Binomialverteilung approximieren

Die Binomialverteilung kann mit der Normalverteilung approximiert werden, **bedingung ist**

$$X \sim B(n,p) \overset{a}{=} N(n \cdot p, n \cdot p \cdot (1-p))$$

falls gilt

$$n \cdot p \cdot (1-p) > 9$$

Die Binomialverteilung kann mit der Poisson Verteilung approximiert werden, dann gilt

$$\lambda = n \cdot p$$

Hypergeometrische Verteilung

Ohne zurücklegen, Wahrscheinlichkeit ändert sich nach jedem Ereignis

$$X \sim H(N,M,n)$$

$n =:$ Stichprobenumfang

$N =:$ Gesamtzahl

$M =:$ Anzahl der Elemente mit der Eigenschaft

$$P(X = k) = \frac{\binom{M}{k} \cdot \binom{N-M}{n-k}}{\binom{N}{n}}$$
$$P(X \leq k) = \sum_{i=0}^{k}\frac{\binom{M}{i} \cdot \binom{N-M}{n-i}}{\binom{N}{n}}$$
$$P(X > k) = 1 - P(X \leq k)$$

Hypergeometrische Vert. apporximieren

Die hypergeometrische Verteilung kann mit der **Binomialverteilung** approximiert werden. Dabei muss folgende Bedingung gelten

$$\frac{n}{N} < 0,05$$

Poisson Verteilung

Schlüsselwörter sind **Ereignisse pro Zeiteinheit**, zum Beispiel Anrufe innerhalb bestimmter Zeitspanne

$X \sim Pois(\lambda)$

$P(X = k) = \pi_\lambda(k) = \frac{\lambda^k}{k!} \cdot e^{-\lambda}$

Geometrische Verteilung

$X \sim Geom(n, p)$

$P(X = n) = (1 - p)^{n-1} \cdot p^n$

Beispiel: Ein Würfel wird so lange gewürfelt bis eine 6 Auftritt. Die Zufallsvariable X ist gleich Anzahl der Würfe

Stetige Verteilungen

Dichtefunktion

Die Dichtefunktion ist ein Hilfsmittel zur **Beschreibung einer stetigen Wahrscheinlichkeitsverteilung**

Bedingungen der Dichtefunkion

$f(x) \geq 0$

$\int_{-\infty}^{\infty} f(x)dx = 1$

Die Dichtefunktion muss **nicht** stetig sein

Die Dichtefunktion ist die Ableitung der Verteilungsfunktion $F(x)$

Verteilungsfunktion

Eine Verteilungsfunktion ist eine Funktion F, die jedem x einer Zufallsvariable X genau eine Wahrscheinlichkeit $P(X \leq x)$ zuordnet

$F(x) \to P(X \leq x)$

Bedingungen der Verteilungsfunktion

Die Verteilungsfunktion **muss** stetig sein

Die Verteilungsfunktion **muss** monoton steigend sein

$\lim_{x\to\infty} F(x) = 1$

$\lim_{x\to-\infty} F(x) = 0$

Normalverteilung

$X \sim N(\mu, \sigma^2)$

Ist $X \sim N(0, 1)$ dann heißt sie Standardnormalverteilt

Jede Normalverteilung kann standardisiert werden, das heißt die Mitte der Kurve wird auf den Nullpunkt gesetzt

Wenn $X \sim N(\mu, \sigma^2)$ verteilt ist dann ist die standardisierte Zufallsvariable

$Z = \frac{x-\mu}{\sigma} \sim N(0, 1)$ standardnormalverteilt

Ist die Zufallsvariable standardverteilt kann die Wahrscheinlichkeit aus der Tabelle abgelesen werden

$P(X \leq k) = \Phi(k)$

$P(X = k) = \Phi(k) = 0$

$P(X \leq -k) = 1 - \Phi(+k)$

allgemein gilt

$X \sim N(\mu, \sigma^2)$

$P(X \leq k) = \Phi(\frac{k-\mu}{\sigma})$

Quantile der Normalverteilung

Tabelliert ist das $\beta-$Quantil z_β der Normalverteilung $N(0, 1)$

$P(X \leq z_\beta = \beta$

$z_{1-\beta} = -z_\beta$

Beispiel

$\beta = 0.9 => z_\beta = 1.28155$

Exponentialverteilung

Eine exponentialverteilte Zufallsvariable T hat die Dichte

$$f(t) = \begin{cases} \lambda \cdot e^{-\lambda \cdot t}, t \geq 0 \\ 0, t < 0 \end{cases}$$

und daraus eribt sich die Verteilungsfunktion

$F(x) = P(T \leq x) =$

$$= \int_{-\infty}^{x} f(t)dt = \begin{cases} 1 - e^{-\lambda \cdot x}, x \geq 0 \\ 0, x < 0 \end{cases}$$

Die Exponentialverteilung ist Gedächtnislos

Erwartungswert und Varianz

Erwartungswert

Erwartungswert und Mittelwert sind prinzipiell gleichwertig, der Erwartungswert entspricht der theoretischen Erwartung, der Mittelwert entspricht den tatsächlichen Werten

Zufallsvariable mit diskreter Verteilung

$\mu = E(X) = \sum_{i=0}^{n} (x_i \cdot p_i)$

Zufallsvariable mit Dichtefunktion f

$\mu = E(X) = \int_{-\infty}^{\infty} x \cdot f(x)dx$

Exponentialverteilung mit Zufallsvariable T

$E(T) = \sigma_T = \frac{1}{\lambda}$

Für Binomialverteilung

$\mu = E(X) = n \cdot p$

Für geometrische Verteilung

$\mu = E(X) = \frac{1}{p}$

Für Poissonverteilung

$\mu = E(X) = \lambda$

Für Hypergeometrischeverteilung

$E(S_n) = E(X_1 + ... + X_n) = n \cdot E(X_1) = n \cdot \frac{M}{N}$

Für Rechteckverteilung

$E(T_i) = \frac{a+b}{2}$

Allgemeine Regeln für den Erwartungswert

$a, b \in \mathbb{R}$

$E(aX + b) = a \cdot E(X) + b$

$E(X + Y) = E(X) + E(Y)$

$E(aX + bY) = a \cdot E(X) + b \cdot E(Y)$

Varianz

Zufallsvariable mit diskreter Verteilung

$\sigma^2 = Var(X) = \sum(x_i - \mu)^2 \cdot p_i$

Zufallsvariable mit Dichtefunktion f

$Var(X) = E(X^2) - (E(X))^2$

Exponentialverteilung mit Zufallsvariable T

$Var(T) = \frac{1}{\lambda^2}$

Für Binomialverteilung

$\sigma^2 = n \cdot p \cdot (1 - p)$

Für geometrische Verteilung

$\sigma^2 = \frac{1}{p^2} - \frac{1}{p}$

Für Poissonverteilung

$\sigma^2 = Var(X) = E(X^2) - E(X)^2 = \lambda$

Für Hypergeometrischeverteilung

$Var(S_n) = n \cdot \frac{M}{N} \cdot (1 - \frac{M}{N}) \cdot \frac{N-n}{N-1}$

Für Rechteckverteilung

$Var(T_i) = \frac{(b-a)^2}{12}$

Allgemeine Regeln für Varianz

$Var(X + Y) =$
$Var(X) + Var(Y) + 2 \cdot cov(X, Y)$

Unabhängiger Zufallsvariablen

Allgemeine Regeln

$E(X \cdot Y = E(X) \cdot E(Y)$

$Var(X + Y) = Var(X) + Var(Y)$

Wichtige Sätze der Stochastik

Zentraler Grenzwertsatz

n groß (Anzahl der Zufallsvariablen) $n \geq 30$

X_i unabhängig und identisch verteilt

$\widehat{=}$ haben die gleiche Verteilung

$E(X_i) = \mu$

$Var(X_i) = \sigma^2$

$\sum X_i \sim N(n \cdot \mu, n \cdot \sigma^2)$

$\frac{1}{n} \sum_{i=1}^{n} = \bar{x} \sim N(\mu, \frac{\sigma^2}{n}$

Manche Verteilungen verhalten sich in der Summe anders, zum Beispiel die Rechteckverteilung ist nicht mehr R-Verteilt. Dann wird der Zentrale Grenzwertsatz verwendet

Induktive Statistik - Schätztheorie

Konfidenzintervalle

Intervall für $E(X)$ einer Normalverteilung

Bei bekannter Standardabweicheung

Ist $X \sim N(\mu, \sigma^2)$ verteilt, dann ist

$Z = \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim N(0, 1)$

$\bar{X}$ = erwartungsstreuer Schätzer bei n unabhängigen Stichproben

Ist α gegegeben, berechne das Quantil

$z_{1-(\alpha/2)}$

Daraus erhält man das Konfidenzintervall

$\left[\bar{x} - z_{1-(\alpha/2)} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{1-(\alpha/2)} \cdot \frac{\sigma}{\sqrt{n}}\right]$

Allgemeine Matheregeln

Potenzen und Logarithmen

Potenzgesetze

$a^0 = 1$

$a^1 = a$

$a^m \cdot a^n = a^{m+n}$

$(a^n)^m = a^{n \cdot m}$

$a^n \cdot b^n = (a \cdot b)^n$

$a^{-n} = \frac{1}{n}$

$\frac{a^n}{a^m} = a^{n-m}$

$a^{\frac{b}{n}} = \sqrt[n]{b}$

Logarithmusregeln

$$x = \log_a y \Leftrightarrow y = a^x$$
$$\log 1 = 0$$
$$\log x \cdot y = \log x + \log y$$
$$-\log x = \log \frac{1}{x}$$
$$\log \frac{x}{y} = \log x - \log y$$
$$\log x^n = n \cdot \log x$$
$$\log_a x = \frac{\log x}{\log a}$$

Ableitungen und Integrale

Grundlegende Ableitungsregeln

$f(x)$	$f'(x)$
$c = const$	0
x^n	$n \cdot x^{n-1}$
$\sqrt{x}$	$\frac{1}{2\sqrt{x}}$
e^x	e^x
a^x	$\ln a \cdot a^x$
$\ln x$	$\frac{1}{x}$
$\log_a x$	$\frac{1}{\ln a \cdot x}$
$\sin x$	$\cos x$
$\cos x$	$-\sin x$
$\tan x$	$\frac{1}{\cos^2 x}$
$\cot x$	$\frac{1}{\sin^2 x}$

Verknüpfte Ableitungsregeln

$f(x)$	$f'(x)$
$(f(x) + g(x))$	$(f'(x) + g'(x))$
$(f(x) \cdot g(x))$	$(f'(x) \cdot g(x)) + (f(x) \cdot g'(x))$
$\frac{f(x)}{g(x)}$	$\frac{(f'(x) \cdot g(x)) - (f(x) \cdot g'(x))}{g(x)^2}$
$[f(g(x)]$	$f'(g(x)) \cdot g'(x)$

wichtige Stammfunktionen

$f(x)$	$F(x)$
$x^n, n \neq 1$	$\frac{1}{n+1} \cdot x^{n+1} + c$
$\frac{1}{x}, x \neq 0$	$\|\ln x\| + c$
$\sqrt{x}$	$\frac{2}{3} \cdot x^{\frac{3}{2}} + c$
e^x	$e^x + c$